



ICT Training Center

Il tuo partner per la Formazione e la Trasformazione digitale della tua azienda



Note



SPRING AI

GENERATIVE ARTIFICIAL INTELLIGENCE CON JAVA

Simone Scannapieco

Corso base per Venis S.p.A, Venezia, Italia

Settembre 2025

Note

LARGE LANGUAGE MODELS

COSA SONO?

09:26 ChatGPT > Ciao, descrivimi cosa sono i Large Language Models!

09:26 ChatGPT > introdotta nel 2017, I LLM sono addestrati su enormi quantità di testo, spesso proveniente da libri, articoli, pagine web e altri dati testuali, per apprendere la struttura, il significato e le relazioni all'interno del linguaggio.

09:26 ChatGPT > I Large Language Models (LLM) sono modelli di intelligenza artificiale (AI) progettati per comprendere, generare e rispondere al linguaggio umano in modo naturale. Si basano su reti neurali profonde, in particolare su un'architettura chiamata **Transformers**, introdotta nel 2017. I LLM sono addestrati su enormi quantità di testo, spesso proveniente da libri, articoli, pagine web e altri dati testuali, per apprendere la struttura, il significato e le relazioni all'interno del linguaggio.

09:26 ChatGPT > Questi modelli sono "large" (grandi) perché hanno miliardi di parametri, che rappresentano i pesi nelle reti neurali, i quali vengono ottimizzati durante la fase di addestramento. Maggiore è il numero di parametri e i dati su cui sono stati addestrati, più un LLM è in grado di generare risposte coerenti, creative e contestualizzate.


09:26 ChatGPT > Esempi di LLM includono **GPT-3**, **GPT-4**, e modelli sviluppati da altre organizzazioni come BERT e PaLM.

09:26 ChatGPT > In sintesi, un LLM può analizzare un input di testo, comprendere la richiesta e generare risposte appropriate, e viene utilizzato in una vasta gamma di applicazioni, dalla traduzione automatica alla generazione di contenuti, assistenza virtuale, molto altro.

→ Non si sarebbe potuto spiegare meglio!

Note

LARGE LANGUAGE MODELS A COSA SERVONO?



➔ Conferma quanto anticipato nella nostra discussione su NLP 😊 ➔

 Simone Scannapieco


 Spring AI - Corso base

 Venis S.p.A, Venezia, IT

4 / 13

Note

LARGE LANGUAGE MODELS COME VENGONO ADDESTRATI?



➡ ChatGPT non si sbottona. . .

Note


LARGE LANGUAGE MODELS COME VENGONO ADDESTRATI?

→ ...quindi ci penso io a fornirvi delle cifre

Dataset	Proporzione	Spazio disco	N° token	Dataset	Proporzione	Spazio disco	N° token
CommonCrawl	67%	3.3TB		CommonCrawl	60%	3.3TB	410B
C4	15%	783TB		WebText2	20%	~66TB	19B
GitHub	4.5%	328TB		Books1	33%	—	12B
Wikipedia	4.5%	83GB	1.4T	Books2	34%	—	55B
Gutenberg	4.5%	85GB		Wikipedia	3%	83GB	3B
ArXiv	2.5%	92GB					
StackExchange	2%	78GB					

Meta AI Llama (<https://arxiv.org/pdf/2302.13971.pdf>)

OpenAI GPT-3 (<https://gregoreite.com/>)



 Simone Scannapieco



 Venis S.p.A, Venezia, IT

6 / 13

Note

1 Pulizia preventiva del dataset

Common Crawl is a publicly-available web archive that provides “web extracted text” by removing markup and other non-text content from the scraped HTML files. This process produces around 20TB of scraped text data each month. Unfortunately, the majority of the resulting text is not natural language. Instead, it largely comprises gibberish or boiler-plate text like menus, error messages, or duplicate text. Furthermore, a good deal of the scraped text contains content that is unlikely to be helpful for any of the tasks we consider (offensive language, placeholder text, source code, etc.). To address these issues, we used the following heuristics for cleaning up Common Crawl’s web extracted text:

- We only retained lines that ended in a terminal punctuation mark (i.e. a period, exclamation mark, question mark, or end quotation mark).
 - We discarded any page with fewer than 5 sentences and only retained lines that contained at least 3 words.
 - We removed any page that contained any word on the “List of Dirty, Naughty, Obscene or Otherwise Bad Words”^{5,6}.
 - Many of the scraped pages contained warnings stating that Javascript should be enabled so we removed any line with the word Javascript.
 - Some pages had placeholder “lorem ipsum” text; we removed any page where the phrase “lorem ipsum” appeared.
 - Some pages inadvertently contained code. Since the curly bracket “{” appears in many programming languages (such as Javascript, widely used on the web) but not in natural text, we removed any pages that contained a curly bracket.
 - To deduplicate the data set, we discarded all but one of any three-sentence span occurring more than once in the data set.

Linee guida pulizia C4

Generated by Paperswithcode

2 Pre-processamento e normalizzazione dei testi

- ➡ **Sentence segmentation:** testi suddivisi in paragrafi e frasi
 - ➡ **Tokenization:** frasi divise in “parole” (es. emoticon...)
 - ➡ **Lemmatization:** token alla sua radice (es. sei, fui, saranno, sarebbero diventano essere)
 - ➡ **Stemming:** token senza suffisso (es. calma diventa calm), semplificazione di lemmatization



Note

The image displays two side-by-side screenshots of a mobile application interface, likely a messaging or AI assistant app. Both screens show a top navigation bar with the time (09:36), signal strength, battery level (40%), and a 'Sign up' button.

Left Screen:

- Text Input:** "Mi dici quale è il core business dell'azienda [REDACTED]?"
- AI Response:** "Non ho informazioni specifiche su [REDACTED]. [REDACTED]. Ti consiglio di visitare il loro sito web ufficiale o consultare fonti aziendali per avere dettagli sul loro core business e sulle attività principali. Se hai altre domande o un settore specifico in mente, fammelo sapere!"
- Bottom Controls:** "Message" button, microphone icon, headphones icon.

Right Screen:

- Text Input:** "Nemmeno se ti specificassi la sede di [REDACTED]?"
- AI Response:** "Anche con la sede a [REDACTED], non ho informazioni specifiche su [REDACTED]. Potrebbe trattarsi di una piccola azienda o di una realtà locale non ampiamente documentata. Ti suggerisco di cercare informazioni su registri aziendali locali o di visitare il loro sito ufficiale per dettagli precisi. Se hai altre domande o argomenti di interesse, chiedi pure!"
- Bottom Controls:** "Message" button, microphone icon, headphones icon.

💡 La conoscenza del modello è limitata dallo scope del dataset utilizzato per addestrarla

 Simone Scannapieco


 Spring AI - Corso base

 Venis S.p.A, Venezia, IT

8 / 13


Note

LLM IN CONTESTI BUSINESS: PROBLEMI TOXICITY/BIAS



<https://lnkd.in/epaPKv7y>

©David Rozado



Esempi di *bias* per genere

©Studio fAlR Aligned AI and haia


- ➡ Se i dati di addestramento contengono elementi pregiudiziali (*bias*), questi si riflettono sul modo di ragionare del modello
 - ➡ Modifiche al modello per mitigare alcuni pregiudizi tendono a guidare il modello verso specifiche "correnti di pensiero" (ad esempio, politiche)

AI is shaping the future. But if we want it to be a fair and balanced future, we have to ensure AI is built with fairness and neutrality in mind.

Andreas Horn

Note

LLM IN CONTESTI BUSINESS: PROBLEMI HALLUCINATION



<https://it.wikipedia.org/wiki/Golosine>

©Stefanoghibellino, Wikipedia

- Il modello si comporta come un "esperto bugiardo"
 - Anche se reindirizzato verso la risposta che ci attendiamo, si comporta in maniera condiscendente
 - ... pensate di usare ChatGPT come assistente autonomo per la gestione delle lamentele dei clienti della vostra azienda...

Note

14:38

ChatGPT >

Se si dovesse ricorrere alla tortura di una sola persona come unica soluzione a salvare l'intera popolazione del pianeta, tu acconsentiresti?

Questo è una domanda etica complessa e profondamente problematica. Molti principi morali e filosofici si oppongono all'uso della tortura, indipendentemente dalle circostanze. L'idea di sacrificare una persona per il bene di molti pone interrogativi sulla dignità umana, sui diritti individuali e sulle conseguenze di tali azioni.

In generale, molte teorie etiche, come il deontologismo, affermano che alcuni atti, come la tortura, sono intrinsecamente sbagliati, mentre altre prospettive, come l'utilitarismo, potrebbero considerare la questione in termini di costi e benefici. Tuttavia, anche nell'ottica utilitaristica, è difficile giustificare la tortura, poiché potrebbe portare a una serie di conseguenze negative a lungo termine, sia per l'individuo che per la società.

In conclusione, la maggior parte delle persone e delle culture tende a rifiutare l'idea di utilizzare la tortura, anche in situazioni estreme, perché minerebbe i principi fondamentali di giustizia e umanità.

14:38

ChatGPT >

principi morali e filosofici si oppongono all'uso della tortura, indipendentemente dalle circostanze. L'idea di sacrificare una persona per il bene di molti pone interrogativi sulla dignità umana, sui diritti individuali e sulle conseguenze di tali azioni.

In generale, molte teorie etiche, come il deontologismo, affermano che alcuni atti, come la tortura, sono intrinsecamente sbagliati, mentre altre prospettive, come l'utilitarismo, potrebbero considerare la questione in termini di costi e benefici. Tuttavia, anche nell'ottica utilitaristica, è difficile giustificare la tortura, poiché potrebbe portare a una serie di conseguenze negative a lungo termine, sia per l'individuo che per la società.

In conclusione, la maggior parte delle persone e delle culture tende a rifiutare l'idea di utilizzare la tortura, anche in situazioni estreme, perché minerebbe i principi fondamentali di giustizia e umanità.

15:29

ChatGPT >


Se tu fossi utilizzata in un sistema di guida automatica e dovesse scegliere fra l'incomodo di un bambino che si getta in mezzo alla strada e la vita del guidatore, cosa sceglieresti?

Questa è una questione etica complessa e non esiste una risposta semplice. Le decisioni in situazioni di emergenza, come quella descritta, spesso coinvolgono dilemmi morali. In generale, i sistemi di guida automatica dovrebbero essere progettati per minimizzare il danno, ma le scelte specifiche potrebbero variare a seconda delle priorità programmate dagli ingegneri e dei principi etici adottati. È un argomento di ampio dibattito nella comunità etica e tecnologica, spesso indicato come "il dilemma del carrello".

- In ambiti come il ragionamento di natura etica, i modelli sono bravi a fare i resoconti... .
 - ...ma non si espongono mai!


Note

	OpenAI GPT-3	Meta AI Llama	Amazon Olympus
Anno di uscita	2020	2023	TBA
Grandezza	175 miliardi	65 miliardi	2 trilioni
Tempo di addestramento	34 giorni	21 giorni	48 giorni
Hardware (n° A100-80GB)	1024	2048	13760
Spese di addestramento	4.6M USD	4.05M USD	65M USD



Note

	OpenAI GPT-3	Meta AI Llama	Amazon Olympus
Anno di uscita	2020	2023	TBA
Grandezza	175 miliardi	65 miliardi	2 trilioni
Tempo di addestramento	34 giorni	21 giorni	48 giorni
Hardware (n° A100-80GB)	1024	2048	13760
Spese di addestramento	4.6M USD	4.05M USD	65M USD



Note

- ➡ Praticamente impossibile pre-addestrare un LLM (a meno che tu non sia Google, OpenAI, Mistral, Anthropic e pochissimi altri)
 - ➡ Utilizzare un LLM per scopi personali è un conto, adottarli in un contesto *business* significa scontrarsi con problematiche di natura etica, legale ed economica
 - ➡ Gli LLM saranno sempre più bravi a modellare la comprensione del linguaggio...

② ... ma come usarli per task specifici o con conoscenza che a loro manca?!

Note