dgroove
Tecnologia emozionale.

# ICT Training Center

**Il tuo partner per la Formazione e la Trasformazione digitale della tua azienda**


# Spring AI

## Generative Artificial Intelligence con Java

Simone Scannapieco

Corso base per Venis S.p.A, Venezia, Italia

Settembre 2025

# Prompt Engineering

## Tecniche di base

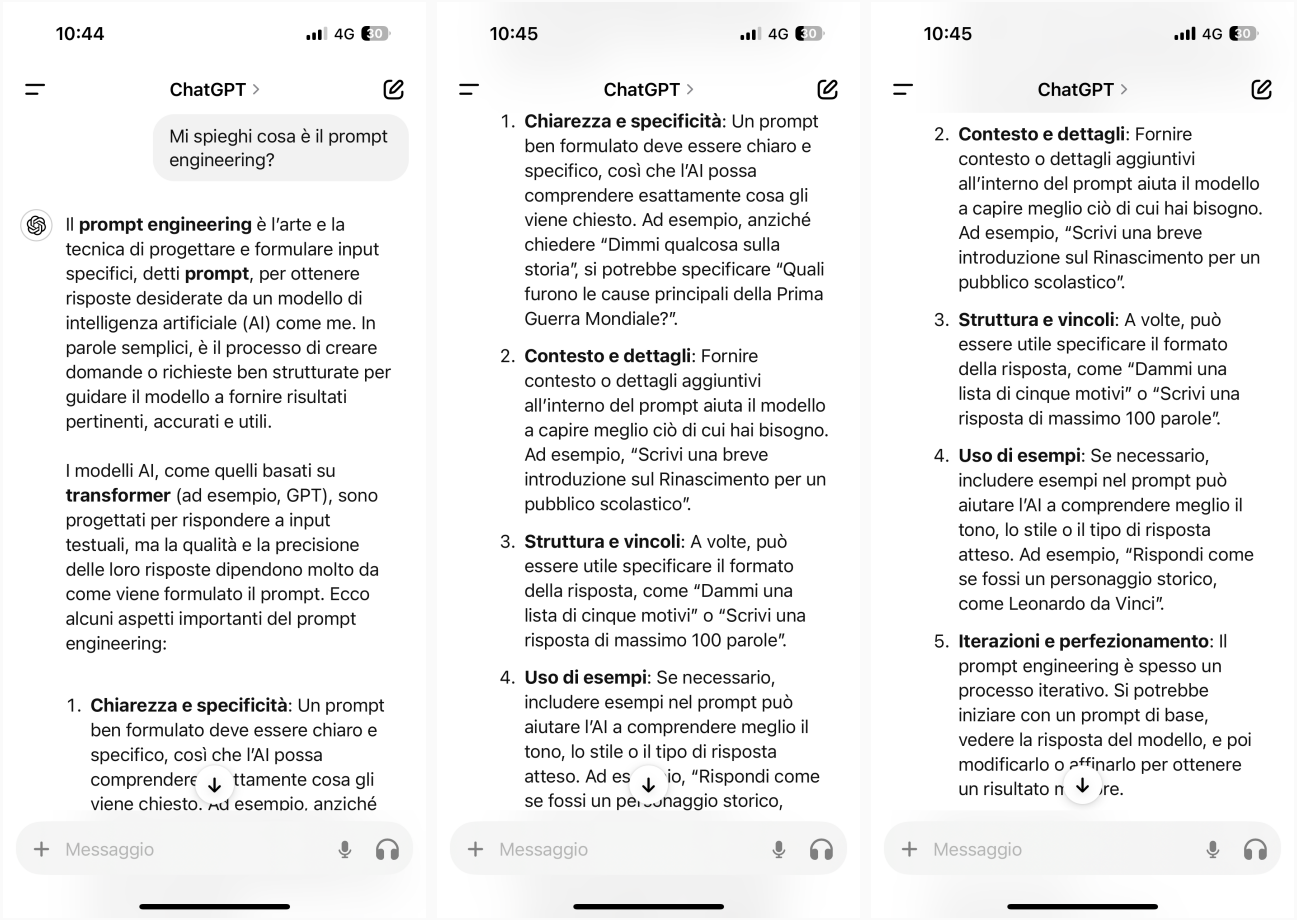


Definiamo meglio il concetto di *prompt*. . .

- Sceglie uno specifico modello da ottimizzare
- Capisce come è stato addestrato il modello
- Capisce come è stato configurato il modello
- Comprende come riconfigurare il modello
- Si esprime efficacemente con il modello
  - Stile
  - Tono
  - Struttura
  - Scelta delle parole
- ⚠ Spinge il LLM verso un comportamento pseudo-deterministico


The Mentalist

*©Prime Video*

1. Lunghezza massima: numero di *token* massimo generato dal modello
   - Evitare alti consumi (energetici, economici, …)
   - Abbattere i tempi di risposta
   - Cruciale in alcuni tipi di strategie di *prompting* (ReAct) e per alcune tipologie di *task*
   - ⚠ Non impone modifiche stilistiche al modello!

2. Creatività del modello: libertà nella scelta del *token* successivo
   - Temperatura:
     - Bassa se vogliamo risposte più deterministiche
     - Alta per risposte “creative”
     - ⚠ Intervallo $[0, +\infty]$
   - Top-K: seleziona i primi K *token* più probabili dalla distribuzione
     - ⚠ Intervallo $[0, +\infty]$
   - Top-P: seleziona i *token* più probabili e la cui probabilità cumulativa non supera P
     - ⚠ Intervallo $[0, 1]$
   - ⚠ Non sempre tutti disponibili!
     - Se tutte disponibili, Top-K e Top-P scremano, temperatura decide
     - Se temperatura manca, Top-K e Top-P scremano, processo *random* decide

### Attenzione alle configurazioni *borderline*

| *Setup* | Effetto |
|---|---|
| Temp $= 0$ | Top-P, Top-K irrilevanti (*greedy decoding*) |
| Temp $\gg 0$ | Temp irrilevante |
| Top-K $= 1$ | Temp, Top-P irrilevanti (*greedy decoding*) |
| Top-K $\gg 1$ | Decide Temp ma processo decisamente *random* |
| Top-P $= 0$ | Temp, Top-K irrilevanti (per maggioranza dei modelli) |
| Top-P $= 1$ | Top-P irrilevante |

Yzma e Kronk

*©Disney*

### Per iniziare (secondo Google)

| **Obiettivo** | **Temp** | **Top-P** | **Top-K** |
|---|---|---|---|
| Risposte formali | .2 | .95 | 30 |
| Risposte creative | .1 | .9 | 20 |
| Risposte molto creative | .9 | .99 | 40 |
| Risposta matematica | 0 | — | — |

3. Sequenze di terminazione: bloccano la terminazione della generazione
   - Generazione di una lista di non più di 10 punti $\rightsquigarrow$ `stop_sequence=[11]`
4. Penalità di ripetizione: incentivare il modello a sfruttare la ricchezza del suo dizionario
   - *Frequency penalty:* penalità calcolata su ciascun *token* proporzionale al numero di apparizioni nella sequenza generata
   - *Presence penalty:* penalità globale indipendente da *token* o numero di occorrenze

| | |
|---|---|
| Direttive | istruzioni specifiche relative alla *task* da eseguire |
| Esempi | per guidare il LLM verso un *output* più efficace |
| Ruolo (persona) | la prospettiva che il LLM deve adottare per definire tono, stile e contenuto della risposta |
| “Contesto” | informazioni aggiuntive che possono indirizzare e addestrare il modello in modo che generi risposte migliori, pertinenti e coerenti con l’obiettivo |
| Dati di *input* | il testo contenente l’istanza della *task* da risolvere |
| Indicatore di *output* | la tipologia o il formato che si vuole ottenere nella risposta |

- Dati di *input* obbligatori
- Altri dati opzionali

- Direttive
  - Essere chiari e concisi
  - Evitare istruzioni ambigue e vaghe
  - Quando possibile, utilizzare verbi che decrivono le azioni da eseguire (“Traduci”, “Fai una lista di …”)
- Esempi
  - Chiari e rilevanti per la *task*
  - Mostrare la struttura o contenuto atteso
  - Numero di esempi comminato alla complessità della *task*
- Ruolo (persona)
  - Aggiungere *expertise* o una prospettiva specifica
  - Ruolo allineato alla *task* (es., esperto di *marketing* per generare contenuto promozionale)
  - Combinare ruolo con il “contesto”

- Contesto
  - Includere informazione strettamente rilevante
  - Informazione strettamente collegata alla *task*
  - Fornire un *background*, soprattutto in sotto-casi specifici
- Indicatore di *output*
  - Se possibile, sfruttare meccanismi automatici ottimizzati (es. `BeanOutputConverter` in Spring AI)

1. Esempi (se necessari)
2. “Contesto” (informazioni aggiuntive)
3. Ruolo (persona)
4. Direttive
5. Dati di *input*
6. Indicatore di *output*

⚠ Evitare che LLM generi ulteriore contesto prima di seguire le istruzioni

*Implicit* solo dati di *input*, senza nemmeno definire le direttive

- Sfruttare le capacità emergenti del LLM

*0-Shot* *task* e dati di *input* specificati, ma priva di esempi

*Few-shots* la richiesta dell'utente è seguita da alcuni esempi su cui la LLM tara il *template* delle risposte da fornire

*Role-based* le informazioni del *prompt* sono suddivise tra una entità *superuser* (*system* o *admin*) e una entità *user*

- Esempi, contesto, direttive e indicatore *output* al *system*
- Dati di *input* allo *user*

*Step-back* suddividere la richiesta finale al LLM in due fasi

- Porre una domanda generica pertinente alla task finale
- Incapsulare la risposta in un nuovo prompt per modellare la task
- Attivare dei percorsi neurali e processi di ragionamento